

서사 상태는 기억이 아니다

페르소나 스토리텔링 시스템을 위한 3축 설계 공간과 NAMS 아키텍처

작업 논문(Working Paper) · SCI 투고 서식

버전 1.0 — 2026년 8월

페르소나 LLM 시장 분석 · 기술 계보 조사 · 최신 연구 비교에 기반함

근거 자료 고지. 본 논문에 인용된 참여도 수치는 기업 블로그·언론 보도·서드파티 앱 분석 등 2차 출처이며 독립 감사를 거치지 않았습니다. 파생 추정치는 "추정"으로 표기했습니다. 정성적 순서(페르소나 플랫폼이 범용 어시스턴트와 구별되는 참여도 영역을 점유한다)는 견고하나, 개별 점추정치를 효과크기 산정에 사용해서는 안 됩니다.

목차

초록

1. 서론

- 1.1 참여도 데이터의 이상 현상
- 1.2 규정의 오류
- 1.3 연구 최전선이 최적화하고 있는 것
- 1.4 기여

2. 실증적 근거

- 2.1 선정 기준
- 2.2 수렴하는 제품 전환

3. 산업 스택이 함축하는 이론

4. 연구 최전선: 세 개의 축, 하나의 보상

- 4.1 네 가지 구조적 공백

5. 정식화: 서사 활력 프론티어

- 5.1 설정
- 5.2 기억 의존도
- 5.3 프론티어
- 5.4 놀라움 예산

6. NAMS: 서사 적응형 메모리 스택

- 6.1 계층 I — 최저 주파수 대역으로서의 페르소나 코어
- 6.2 계층 II — 서사학적 사전지식을 갖춘 내러티브 상태
- 6.3 계층 III — 업계가 이미 데이터를 갖고 있는 다이얼을 학습하기
- 6.4 캐논 중재기 — 3자 저작을 정의 가능하게 만들기

7. 평가 프로토콜

- 7.1 지표
- 7.2 PERSONA-ARC: 종단 벤치마크 설계
- 7.3 NAMS를 반증할 절제 실험

8. 예측

9. 안전, 의존성, 규제 제약

10. 한계

11. 결론

참고문헌

Abstract (English)

초록

페르소나 대규모언어모델(LLM) 플랫폼은 생성형 AI 시대에 1인당 체류시간이 가장 긴 소비자 애플리케이션 범주로 조용히 자리 잡았다. 가장 오래 지속된 세 서비스 — zeta(스캐터랩), Character.AI, Talkie/星野(MiniMax) — 의 현장 데이터는 1인당 하루 70~150분의 사용시간이 수년에 걸쳐 유지되고 있으며, 이는 주요 엔터테인먼트 플랫폼을 상회하는 수준임을 보여준다. 그러나 이 시스템들이 근거로 삼는 연구 문헌은 핵심 난제를 일관되게 **기억(memory)**의 문제, 즉 과거를 얼마나 충실히 회상하고 재주입하는가의 문제로 규정한다. 본 논문은 이 규정이 범주적으로 잘못되었다고 주장한다.

현시점에서 가장 주목받는 세 연구 흐름 — Nested Learning/HOPE(파라메트릭 다중 시간스케일 기억), ALMA(메타러닝 기반 에이전트 메모리 설계 탐색), SteeM(사용자 제어 가능 기억 의존도) — 을 비교 분석한 결과, 세 흐름 모두 **회상 충실도**를 최적화하는 반면, 장기 페르소나 스토리텔링의 실증적 실패 양상은 **앵커링(anchoring)**임을 보인다. 고충실도 회상은 서사적 예측 가능성을 낮고, 예측 가능성은 이탈을 낳는다.

우리는 이를 **서사 활력 프론티어(Narrative Vitality Frontier)**로 정식화한다. 기억 의존도 δ 에 대해 지속 참여도 $V(\delta)$ 는 오목하며 내부 최적점 δ^* 를 가지고, δ^* 는 그 자체가 관계 연령 τ 의 함수로 이동한다. 이어 **NAMS(Narrative-Adaptive Memory Stack)**를 제안한다. 이는 (I) 정체성 불변량을 강제하는 최저 갱신 주파수의 페르소나 코어, (II) 사실이 아니라 서사 변수(아크 위치, 미해결 복선, 관계 단계, 긴장도)를 담는 메타러닝 내러티브 상태 스키마, (III) 플랫폼이 이미 수집하고 있는 상호작용 신호 — 재생성, 수정, 대화 지속 —로부터 δ 를 자동 결정하는 스티어링 컨트롤러의 3계층 분리 구조다.

본 논문은 지표 체계(PCS, NNI, TAR, CAR), 종단 벤치마크 설계(PERSONA-ARC), 네 가지 반증 가능한 예측, 그리고 참여도 극대화를 의존성 및 미성년자 안전 제약 하에 종속시키는 제약형 목적함수를 함께 제시한다. 중심 주장은 다음과 같다. 이 분야의 다음 진보는 더 많이 기억하는 데서 오지 않고, **기억한 것으로 이야기가 무엇을 할지 결정하는 데서 온다.**

주제어: 페르소나 LLM, 인터랙티브 내러티브, 장기 기억, 지속 학습, 기억 앵커링, 인간-에이전트 상호작용, 선호 최적화, AI 안전

1. 서론

1.1 참여도 데이터의 이상 현상

2024년부터 2026년 사이, "AI 컴패니언", "캐릭터 챗", "AI 스토리 플랫폼" 등으로 다양하게 불리는 응용 범주가 생성형 AI 시장의 나머지와는 조화되기 어려운 참여도 수치를 만들어냈다. 범용 어시스턴트의 세션 길이는 대체로 7분대로 수렴한다. 페르소나 플랫폼은 정반대 영역에 있다. Character.AI는 월간 활성 사용자 약 2,000만 명에 대해 DAU/MAU 약 29%를 유지하고, zeta는 액티브 유저 기준 하루 약 150분, DAU/WAU 약 0.75를 보고하며, MiniMax의 星野/Talkie는 하루 70분 이상을 기록한다.

이는 점착도의 한계적 차이가 아니다. 제품의 물리 법칙이 다르다. 7분짜리 어시스턴트 세션은 **거래**이고, 150분짜리 페르소나 세션은 **연재 서사**다. 그리고 연재 서사는 거래가 결코 마주치지 않는 이유로 실패한다. 답이 틀려서가 아니라, 진부해져서, 캐릭터가 무너져서, 복선이 회수되지 않아서, 극적 긴장이 소실되어서 실패한다.

1.2 규정의 오류

이 플랫폼들이 생산하거나 참조하는 공학 문헌은 장기 상호작용을 인프라 문제로 취급한다. Character.AI가 공개한 작업은 서빙 경제성에 집중되어 있다 — 다중 질의 어텐션(MQA; Shazeer, 2019), 로컬/글로벌 어텐션 지평의 혼합, 레이어 간 KV 캐시 공유, 스테이트풀 프리픽스 캐싱, 학습·서빙 int8 정밀도 정합, 그리고 페르소나·기억·안전 텍스트를 토큰 예산 안에서 조립하는 템플릿 계층 Prompt Poet. MiniMax의 베틱은 용량이다. Lightning Attention을 소프트맥스 어텐션과 혼합하고 전문가 혼합(MoE) 백본을 결합해 네이티브 100만 토큰 컨텍스트를 확보했다(MiniMax, 2025a; 2025b). 즉 요약하지 말고 전부 유지하라는 전략이다. 스캐터랩의 베틱은 정렬이다. 유저의 재생성·직접 수정·대화 지속 행동을 DPO(Rafailov et al., 2023)의 선호 신호로 변환하고, 이를 다시 GRPO(Shao et al., 2024) 기반 온라인 러닝으로 확장하며, 매주 프로덕션 모델을 배포한다.

서로 다른 세 병목 — 단가, 용량, 정렬 — 과 하나의 공유된 전제. 즉 시스템이 과거에 대해 지는 의무는 **그것을 정확히 재현하는 것**이라는 전제다.

1.3 연구 최전선이 최적화하고 있는 것

동일한 전제가 장기 상호작용 에이전트에 관한 현재 가장 많이 논의되는 연구를 지배한다. 우리는 기억을 어디에 두는가에서는 상호 직교하지만 무엇을 보상하는가에서는 동일한 세 흐름을 검토한다.

- **HOPE / Nested Learning**(Google Research, 2025)은 모델을 갱신 주기가 서로 다른 중첩 최적화 문제들의 집합으로 재해석하고, 단기/장기 이분법을 연속 기억 시스템(CMS)으로 대체한다. 목표는 파국적 망각의 완화와 장문 검색이다.
- **ALMA**(Xiong, Hu & Clune, 2026)는 사람이 손으로 짠 메모리 모듈을, 메타 에이전트가 실행 가능한 코드로 발견하는 메모리 설계로 대체한다. 평가는 순차적 의사결정 성공률이다.

- **SteeM**(Tian et al., 2026)은 기억 의존도를 행동적 양으로 정량화하고, fresh-start에서 high-fidelity에 이르는 사용자 대면 다이얼로 노출한다.

셋 중 마지막 하나만이 기억이 많을수록 나빠질 수 있음을 인정한다. 그마저도 결정을 사람의 슬라이더에 위임한다.

1.4 기여

1. **실증적 근거**(2장): 다운로드·투자 규모가 아니라 규모 $\times$ 체류 $\times$ 지속 기준으로 가장 오래 점유하는 세 페르소나 플랫폼을 선정한다.
2. **비교 분해**(4장): 선도적 세 기억 연구 흐름을 소재/주체/시간스케일 분류축으로 분해하고 네 가지 구조적 공백을 분리한다.
3. **정식화**(5장): 앵커링-혁신 긴장을 서사 활력 프론티어로 정식화한다. 제어 변수는 기억 의존도 δ , 표준 매개변수는 관계 연령 τ 다.
4. **NAMS**(6장): 각 연구 흐름을 실제로 하중을 지는 계층에 배치한 3계층 아키텍처와, 기존 정식화가 모두 무시해 온 3자 공동저작(제작자/플레이어/모델) 구조를 위한 캐논 중재 기제를 제안한다.
5. **평가 프로토콜**(7장): 서사 고유 지표 4종과 종단 벤치마크 설계로 학계 지표와 산업 리텐션 지표를 잇는다.
6. **네 가지 반증 가능한 예측**(8장)과, 무제약 참여도 극대화를 안전하지 않은 것으로 취급하는 **제약형 목적함수**(9장).

2. 실증적 근거

2.1 선정 기준

플랫폼이 다음 세 조건을 모두 만족할 것을 요구한다. (i) $MAU \geq 10^6$, (ii) 액티브 유저 1인당 일 체류 ≥ 60 분, (iii) 공개된 참여도 기록을 동반한 24개월 이상 연속 운영. 다운로드, 기업가치, 언론 노출량은 점유가 아니라 획득을 측정하므로 제외한다.

표 1. 선정된 플랫폼과 참여도 근거(2026년 8월 기준).

플랫폼	운영사 / 출시	규모	액티브 1인 당 일 체류	점착도	모델 소유
zeta	스캐터랩(KR), 2024-04	가입 615만, WAU 120만, DAU 90만 (2026-02)	약 150분, 주 10시간 이상	DAU/ WAU ≈ 0.75	자체 sLM(Pingpong-1) + 외부
Character.AI	Character Technologies(US), 2022-09	MAU 약 2,000만, DAU 약 580만 (2024년 피크 2,800만)	세션 17.4 분, 일 약 2 시간(추정)	DAU/ MAU ≈ 0.29	자체 모델, Google 라이선 스(2024)
Talkie / 星野	MiniMax(CN), 2023	Talkie MAU 약 1,100만 (2024-07), 星野 MAU 460 만(2025-12)	70분 이상	미공개	파운데이션 스택 전체 (MiniMax-01/M1/M2)

출처는 모두 2차 자료(기업 블로그, 언론 보도, 서드파티 앱 분석)이며 독립 감사를 거치지 않았다. "추정"으로 표기한 값은 보고된 값이 아니라 파생된 값이다. 정성적 순서 — 페르소나 플랫폼이 범용 어시스턴트보다 한 자릿수 위의 참여도 영역을 점유한다는 것 — 는 참조한 모든 출처에서 견고하다.

2.2 수렴하는 제품 전환

서로 독립적으로, 그리고 약 12개월 이내에, 세 운영사 모두 동반(companionship)에서 저작(authorship)으로 포지션을 이동했다. zeta는 스스로를 AI 스토리 플랫폼으로 규정하며 ML 조직을 **내러티브 트랙, 브레인 트랙, 플레이어 경험 트랙**으로 명시적으로 분할했다. Character.AI의 2025년 이후 경영진은 "AI 컴패니언"에서 "롤플레이팅 창작 플랫폼"으로의 전환을 공언했다. MiniMax는 Talkie에 구조화된 롤플레이와 캐릭터 정합 음성을 얹었다.

이 수렴이 본 논문의 실증적 정당화다. 병목도, 규제 환경도, 언어도 다른 세 조직이 같은 결론에 도달했다. 지속되는 **참여의 단위는 대화가 아니라 이야기다**. 그러나 이들의 기술 스택은 여전히 대화를 모델링한다.

3. 산업 스택이 함축하는 이론

표 2. 각 운영사가 병목이라고 믿는 것.

	zeta	Character.AI	MiniMax / Talkie
함축된 병목	정렬: 무엇이 재미있는가	단위 경제: 긴 세션을 싸게	용량: 전부 보존하기
대표 기법	재생성·수정 신호 기반 DPO → GRPO 온라인 러닝, 주간 배포	MQA, 하이브리드 어텐션 지평, 레이어 간 KV 공유, 스테이트풀 프리픽스 캐싱, int8 정합, Prompt Poet	Lightning Attention(선형+소프트맥스 혼합), MoE(총 456B / 활성 45.9B), 네이티브 100만 토큰
기억 전략	요약 + 조립 + 선호 학습	토큰 예산 하 템플릿 조립	원문 히스토리를 컨텍스트에 유지
서사 상태	암묵적(프롬프트 텍스트)	암묵적(프롬프트 텍스트)	암묵적(원문 히스토리)

각 스택은 자신이 선택한 병목에 대한 일관된 해답이다. 그러나 셋 중 어느 것도 이야기가 지금 어디에 있는가에 대한 명시적 표현을 유지하지 않는다. 아크 위치, 회수되지 않은 설정, 갈등의 고조, 관계의 단계는 오직 프롬프트 내부의 비구조화된 자연어로만 존재하며, 이는 극적 중요도가 아니라 토큰 예산을 기준으로 설계된 절단(truncation) 정책의 지배를 받는다. LLM에서 이미 보고된 다중 턴 성능 저하 현상(Liu et al., 2023; Laban et al., 2025)을 고려하면, 이는 가장 먼저 손상될 가능성이 높은 표현 형식이다.

4. 연구 최전선: 세 개의 축, 하나의 보상

표 3. 비교 분해.

비교축	HOPE / Nested Learning	ALMA	SteeM
기억의 소재	가중치(다중 시간스케일)	외부 모듈(실행 가능 스키마)	컨텍스트 주입 강도
적응 주체	모델 자신(자기수정)	설계를 탐색하는 메타 에이전트	사용자
시간 스케일	연속 주파수 스펙트럼(CMS)	과업 시퀀스 단위	턴 / 세션 단위
망각의 처리	주파수 분리로 파국적 망각 완화	무엇을 버릴지 학습	낮은 의존도로 의도적 무시
최적화 대상	perplexity, 장문 검색, CL 벤치마크	과업 성공률과 효율	앵커링/혁신 균형
배포 준비도	낮음(공식 구현 부재)	중간(탐색 비용)	높음(기존 스택에 즉시 적용)
페르소나 서사에서 하중을 지는 지점	수개월 단위 정체성 항상성	세계관·관계 스키마의 자동 발견	서사적 매너리즘 탈출
특징적 실패	느린 페르소나 표류	최적이지만 재미없는 정책으로 수렴	사용자가 다이얼을 만지지 않음

4.1 네 가지 구조적 공백

G1 — 회상 충실도를 단조 증가하는 선(善)으로 취급한다. 과업 환경에서는 방어 가능한 가정이지만 서사 환경에서는 거짓이다. 완벽한 회상은 일관성을, 일관성은 예측 가능성을 낳고, 예측 가능성은 연재 픽션에서 이탈의 근인(近因)이다. SteeM만이 이 긴장을 기억 앵커링이라는 이름으로 명명했고, 그 해결을 사용자에게 수출했다.

G2 — 서사 구조가 어디에서도 상태 변수가 아니다. 어떤 정식화도 미해결 복선, 아크 위치, 관계 단계, 긴장도를 1급 상태로 갖지 않는다. ALMA는 원리적으로 그러한 스키마를 발견할 수 있으나, 과업 성공률로 보상받는 메타 에이전트는 "회수되지 않은 체호프의 총 개수"를 필드로 제안하지 않는다.

G3 — 단일 저자를 가정한다. 페르소나 플랫폼은 3자 저작이다. **제작자**가 캐릭터 카드와 세계관을 쓰고, **플레이어**가 그 안에서 그리고 그에 맞서 즉흥하며, **모델**이 생성한다. 캐논 충돌 — 플레이어가 제작자 카드와 모순되는 사실을 주장하는 경우 — 에 대해 우리가 검토한 어떤 메모리 프레임워크도 해소 의미를 정의하지 않는다. 이는 공학의 공백이 아니라 명세의 공백이다.

G4 — 지표의 단절. 연구는 perplexity와 성공률을 보고하고, 운영사는 D7 리텐션과 일 체류시간을 보고한다. 둘을 잇는 것이 없으므로 실험실의 개선은 전이되지 않고 제품의 학습은 일반화되지 않는다.

5. 정식화: 서사 활력 프론티어

5.1 설정

페르소나 명세를 $\mathbf{P}$ (정체성 불변량, 목소리, 관계, 금지사항), 세계관 명세를 $\mathbf{W}$ 라 하자. 턴 t 에서 상호작용 이력을 $H_t = (u_1, a_1, \dots, u_t)$, 메모리 저장소를 M_t , 검색 연산자를 ρ 라 하자. **내러티브 상태**를 다음과 같이 정의한다.

$$S_t = (A_t, O_t, R_t, T_t)$$

여기서 $A_t \in [0,1]$ 은 정규화된 아크 위치, O_t 는 연령과 현저성을 가진 미해결 서사 실타래의 다중집합, R_t 는 플레이어 캐릭터와 페르소나 사이의 관계 단계, $T_t \in \mathbb{R}^+$ 는 극적 긴장도다. 생성 정책은 다음과 같다.

$$a_t \sim \pi_\theta(\cdot \mid P, W, \rho(M_t, c_t), S_t)$$

기존 시스템은 이를 $S_t \equiv \emptyset$ 로 구현하며, 모든 서사 정보를 $\rho(M_t, c_t)$ 안에 접어 넣는다.

5.2 기억 의존도

SteeM의 행동적 구성을 따라, **기억 의존도**를 기억 주입이 있는 정책과 없는 정책 사이의 발산으로 정의한다.

$$\delta_t = D(\pi_\theta(\cdot \mid \rho(M_t, c_t)) \parallel \pi_\theta(\cdot \mid \emptyset))$$

D 는 표집된 연속 발화에 대해 추정되는 f-발산이다(실무적으로는 표집된 응답 집합 간의 정규화된 임베딩 거리로 충분하고 저렴하다). $\delta = 0$ 은 기억상실, $\delta \rightarrow \delta_{\max}$ 는 고충실도 앵커링이다. δ 는 저장된 기억의 양이 아니라 **기억이 현재 행사하는 행동적 권한의 크기**에 유의하라.

5.3 프론티어

V 를 지속 참여도 — 조작적으로는 사용자의 이야기가 세션 $n+1$ 까지 생존할 확률을 D7/D30 리텐션으로 집계한 값 — 라 하자. 우리는 다음을 가설로 세운다.

H0 (활력 프론티어). 고정된 페르소나와 플레이어에 대해 $V(\delta)$ 는 $[0, \delta_{\max}]$ 위에서 오목하며, 기억상실과 완전 회상 사이의 진성 내부 최대점 δ^* 를 갖는다.

기제는 서로 경쟁하는 두 단조 항이다.

$$V(\delta) \approx \alpha \cdot \text{일관성}(\delta) - \beta \cdot \text{예측가능성}(\delta) + \gamma$$

일관성은 포화한다(페르소나가 내 이름과 최근 세 비트를 안정적으로 기억하는 순간부터, 추가 충실도의 한계 효용은 급감한다). 반면 예측 가능성은 계속 상승한다(과거가 현재를 결정할수록 새로운 비트가 실어 나르는 정보량은 줄어든다). 포화하는 첫 항에서 대략 선형인 둘째 항을 빼면 오목성이 따라 나온다.

H1 (표류). δ^* 는 정상적(stationary)이지 않다. $\delta^*(\tau)$ 는 형성기(대략 처음 10^2 – 10^3 턴, 일관성이 희소하고 회상된 세부 하나하나가 관계의 실재성을 입증하는 증거인 구간)에 상승하고, 누적된 이력이 다음 비트를 과도하게 결정하기 시작하는 유지기에 하강한다.

H1은 현재 모든 배포 시스템이 사용하는 고정 기억 정책이 사용자 생애주기의 최소한 한 국면에서 반드시 오조정되어 있음을 예측한다. 구체적으로는 체류시간의 대부분을 생산하는 장기 잔존 코호트에서 과도하게 앵커링되어 있다는 예측이다.

5.4 놀라움 예산

프론티어의 다루기 쉬운 대리 지표는 **서사 놀라움 예산(narrative surprisal budget)** 이다. v_t 를 비트당 참신도(7장)라 할 때, 컨트롤러는 V 를 직접 최대화하는 대신 v_t 가 대역 $[v_{lo}, v_{hi}]$ 안에 머물도록 δ_t 를 조절한다. 이 대역 자체는 S_t 에 조건화된다. 상승 국면에서는 넓게, 절정에서는 좁게(이때의 보상은 앞서 심어둔 설정에서 따라 나와야 한다), 해소 이후 다시 넓게. 이로써 기억 제어는 회상의 최대화가 아니라 **서사학적으로 도출된 설정점에 대한 조절(regulation)** 문제로 재구성된다.

6. NAMS: 서사 적응형 메모리 스택

NAMS는 세 연구 흐름을 경쟁자로 두지 않고, 각각이 실제로 하중을 지는 계층에 배치한다.

표 4. NAMS의 3계층.

계층	내용	갱신 주기	대응 연구
III 스티어링 컨트롤러	S_t, τ , 실시간 유저 신호로부터 δ_t 를 결정	턴 단위	SteeM의 일반화 — 다이얼의 자동화
II 내러티브 상태 S_t	아크 위치, 미해결 복선, 관계 단계, 긴장도를 담는 타입화된 스키마	비트/세션 단위	ALMA의 일반화 — 스키마 탐색 + 서사학적 사전지식
I 페르소나 코어	정체성 불변량, 목소리, 금지사항	최저 주파수	HOPE/CMS의 일반화 — 정체성을 최저 주파수 대역에

세 계층을 관통하여 **캐논 중재기**(제작자 ▶ 플레이어 ▶ 모델 우선순위)가 작동한다.

6.1 계층 I — 최저 주파수 대역으로서의 페르소나 코어

Nested Learning의 기여를 이 관점에서 다시 읽으면, 그것은 "더 나은 장문 컨텍스트"가 아니라 **무엇이 느리게 변해야 하는가에 대한 원리적 설명**이다. NAMS에서 페르소나 정체성은 연속 기억 시스템의 가장 느린 대역을 점유한다. 갱신되기는 하되, 에피소드 내용보다 몇 자릿수 낮은 주파수로 갱신된다. 두 가지 귀결이 따른다.

첫째, 페르소나 표류가 일화적 관찰이 아니라 측정 가능한 양이 된다. 표류란 고주파 에피소드 갱신이 저주파 정체성 대역으로 누출되는 현상이며, 페르소나 코어 파라미터의 변화나 고정된 정체성 프로브 집합에 대한 응답 변화로 모니터링할 수 있다.

둘째 — 그리고 통념과 반대로 — **표류를 0으로 몰아붙여서는 안 된다**. 1만 턴 뒤에도 완전히 동일한 캐릭터는 일관된 것이 아니라 죽어 있는 것이다. 캐릭터 성장은 정체성 공간 위의 유계하고 방향성 있는 궤적이다. NAMS는 정체성 불변량(결코 위배되지 않음)과 정체성 변수(제작자가 선언한 축을 따라 이동이 허용됨, 예: "경계하는 → 신뢰하는")를 분리 명세함으로써, 성장을 망각의 우연이 아니라 설계된 어포던스로 만든다.

6.2 계층 II — 서사학적 사전지식을 갖춘 내러티브 상태

ALMA는 메모리 설계 자체가 손으로 쓰이는 대신 발견될 수 있음을 보였다. NAMS는 그 기제를 채택하되 보상을 바꾼다. 두 가지 수정이 필요하다.

1. **서사학적 사전지식으로 탐색을 초기화한다**. 스키마 탐색은 구조주의 서사학의 필드로 초기화된다 — Propp(1928) 전통의 기능/비트 목록, Freytag의 긴장 곡선, 그리고 드라마 매니지먼트와 경험 관리자 매개 같은 인터랙티브 내러티브 구성물(Riedl & Bulitko, 2013). 이는 최종 설계를 제약하지 않는다. 설계 공간의 관련 영역을 도달 가능하게 만들 뿐이며, 이로써 **G2**를 해소한다.
2. **서사 고유 지표로 보상한다**(7장). 과업 성공률로 보상하면 표 3에서 지적한 "최적이지만 재미없는 정책"으로 수렴한다.

계층 II는 이미 산업적으로 배포된 프롬프트 조립 관행(Prompt Poet식 템플릿, 요약 파이프라인)을 타 입화되고 검사 가능한 상태 객체로 전환하는 장치다. 실무적 이득은 즉각적이다. 토큰 압박 하의 절단을 최신순이 아니라 **극적 인식(dramatically-aware)** 으로 만들 수 있다 — 회수되지 않은 설정보다 이미 해소된 실타래를 먼저 버린다.

6.3 계층 III — 업계가 이미 데이터를 갖고 있는 다이얼을 학습하기

SteeM의 핵심 통찰은 δ 가 제어 가능하다는 것이고, 핵심 한계는 "얼마나 기억할까요"라는 슬라이더가 장면 한복판의 플레이어가 답하고 싶어 하지 않는 질문이라는 것이다.

본 논문의 핵심적인 실무적 관찰은 다음과 같다. δ 를 자동으로 학습하는 데 필요한 신호는 이미 프로덕션에서 수집되고 있다. 스캐터랩의 파이프라인은 재생성, 직접 수정, 대화 지속 이벤트를 DPO용 선호 데이터로, 이어 온라인 GRPO 갱신으로 변환한다. 이들은 정확히 앵커링 실패와 일관성 실패를 구분해주는 사건이다.

표 5. 관측된 유저 행동에서 δ 조정으로.

관측된 유저 행동	가장 유력한 원인	올바른 δ 조정
페르소나에 맞고 일관된 응답을 재생성함	지루함 / 예측 가능성	δ 감소
잊힌 사실을 다시 넣으려고 응답을 수정함	일관성 실패	δ 증가
반복된 비트 이후 세션을 이탈함	앵커링	δ 감소, 실타래 강제 교체
빠르게, 긴 턴으로 지속함	대역 내	유지

오늘날 이 신호는 전부 응답 개선에만 소비된다. NAMS는 그 일부를 기억 정책 개선에 배분한다. 형식적으로 계층 III은 컨트롤러 $\pi_{\phi}(\delta_t | S_t, \tau, \text{최근 신호})$ 이며, 이미 사용 중인 그룹 상대 정책 최적화로 5.4절의 놀라움 대역 보상 및 리텐션 연동 종단 보상에 대해 학습된다. 이는 위험이 낮고 수확이 큰 배포 경로다. 새로운 데이터 수집도, 새로운 모델 아키텍처도 필요 없으며, 고정 δ 대조군에 대해 즉시 A/B 검정할 수 있다.

6.4 캐논 중재기 — 3자 저작을 정의 가능하게 만들기

G3를 닫기 위해 NAMS는 메모리에 진입하는 모든 명제에 출처 태그 $\in \{\text{제작자, 플레이어, 모델}\}$ 와 양상 $\in \{\text{캐논, 가설, 철회}\}$ 를 부여한다. 기본 우선순위는 **제작자 ▶ 플레이어 ▶ 모델**이며, 이를 플레이 가능하게 만드는 두 개의 수정 조항을 둔다.

- 플레이어 승격: 플레이어가 저작한 명제가 k 턴 동안 반박 없이 생존하고 제작자 불변량과 충돌하지 않으면 캐논으로 승격된다. 이야기가 공동 소유된다는 감각을 만드는 것이 바로 이 규칙이며, 이는 측정 가능하다(7장의 CAR 참조).

- 모델 강등: 모델이 저작한 명제는 결코 직접 캐논에 진입하지 않는다. 플레이어의 수용에 의해 비준되기 전까지는 가설로 남는다. 이 한 규칙이 배포 시스템에서 가장 흔한 장기 지평 오염 — 환각된 세부가 요약을 거쳐 메모리에 들어가 영구적 진실이 되는 경로 — 를 제거한다.

중재기는 또한 플랫폼 수준 안전 제약이 놓일 원리적 자리를 제공한다. 안전 제약은 어떤 플레이어 승격으로도 무효화할 수 없는 제작자 수준 불변량이다(9장).

7. 평가 프로토콜

7.1 지표

G4를 닫기 위해 서사 고유 지표 4종을 제안한다. 모두 자동 산출 가능하며, 각각 특정 리텐션 행동의 선행 지표로 가설된다.

PCS — 페르소나 일관성 점수(Persona Consistency Score). P로부터 도출한 페르소나 진단 질문의 고정 집합 Q 를 유지한다. 부수 채널로 주기적으로 질의하여 P 및 이전 프로브 응답에 대한 모순율을 채점한다. $PCS = 1 - (1/|Q|) \sum_{q \in Q} 1[\text{모순}]$. 정당한 성장이 실패로 채점되지 않도록 정체성 불변량과 정체성 변수를 나누어 보고한다.

NNI — 서사 참신도 지수(Narrative Novelty Index). 비트 임베딩 e_t 와 직전 k 개 비트 윈도우에 대해 $NNI_t = 1 - \max_{i \in [t-k, t-1]} \cos(e_t, e_i)$. 5.4절 v_t 의 조작적 형태다. 평균이 아니라 분포로 보고한다. 앵커링의 병리는 좌측 꼬리의 붕괴이며, 평균에서는 보이지 않는다.

TAR — 실타래 진전율(Thread Advancement Rate). O_t 의 추적 대상 실타래를 열거나 진전시키거나 닫는 턴의 비율. 동반 통계로 실타래 노후도 = 미해결 실타래 연령의 중앙값을 함께 본다. NNI는 높는데 TAR이 낮은 시스템은 이야기가 아니라 무작위 참신함을 생성하고 있는 것이다.

CAR — 공동저작 비율(Co-Authorship Ratio). 현재 캐논인 명제 중 출처가 플레이어인 것의 비율. 우리는 CAR이 업계에서 가장 계측되지 않은 변수인 동시에, 관측된 "동반 → 저작" 전환과 가장 밀접하게 결합된 변수라고 가설한다.

보조 지표: δ -궤적(실현된 δ_t 시계열), 재생성률, 그리고 검증용 D1/D7/D30 리텐션.

7.2 PERSONA-ARC: 종단 벤치마크 설계

기존 장기 기억 벤치마크는 합성 대화 이력에 대한 검색 정확도를 측정한다. 어느 것도 이야기가 계속할 가치가 있는 상태로 남아 있는지를 측정하지 않는다. PERSONA-ARC는 다음을 명세한다.

- **지평:** 궤적당 10^3 턴 이상, 달력 기준 30일 이상. H1이 고정 δ 시스템의 실패를 예측하는 유지기 영역과 일치시킨다.
- **두 모집단:** (a) 규모와 재현성을 위한, 홀드아웃 플레이어 행동 모델로 구동되는 시뮬레이션 플레이어, (b) 타당성을 위한 인간 플레이어. 시뮬레이션 군은 NNI·TAR 분포에서 인간 군에 대해 보정한다.
- **섭동 세트:** 주입된 캐논 충돌(플레이어가 제작자 카드에 반하는 주장), 장기 부재(7/14/30일 공백), 이야기 도중의 제작자 측 카드 수정. 각각이 특정 중재 규칙 또는 계층을 겨냥한다.
- **1차 종점:** 세션 지속에 대한 생존 분석, 공변량으로 PCS/NNI/TAR/CAR. 이 벤치마크의 목적은 이들 공변량이 생존을 예측함을 확립하는 것이다. 예측하지 못한다면 지표 체계가 틀린 것이므로 폐기해야 한다.

7.3 NAMS를 반증할 절제 실험

- 계층 I만(고정 페르소나, S_t 없음, 고정 δ) $\approx$ 현행 산업 기준선.
- 계층 I + II(명시적 내러티브 상태, 고정 δ): 이야기를 표현하는 것의 가치를 분리.
- 완전 NAMS: δ 를 제어하는 것의 가치를 분리.
- 분산을 맞춘 무작위 보행으로 δ 를 설정한 완전 NAMS: 효과를 낳는 것이 학습된 변동이 아니라 기억 의존도의 임의의 변동일 가능성을 통제한다. 이 절제는 필수적이며, 본 제안을 가장 곤란하게 만들 가능성이 높은 실험이다.

8. 예측

이 틀이 공개적으로 틀릴 수 있도록 네 가지 반증 가능한 예측을 제시한다.

P1. 배포된 페르소나 시스템에서 재생성 이벤트는 일관성 실패 모드와 예측 가능성 모드로 이봉분포를 이룰 것이며, 예측 가능성 모드가 전체 재생성에서 차지하는 비중은 계정 잔존 기간에 따라 증가할 것이다.

P2. 모델 품질을 고정할 때, 학습된 δ 컨트롤러(계층 III)는 최적의 고정 δ 보다 D30 리텐션에서 우수할 것이며, 그 이득은 최장 잔존 십분위 — 체류시간을 가장 많이 생산하고 현재 가장 과도하게 앵커링된 코호트 — 에 집중될 것이다.

P3. NNI 분포의 좌측 꼬리 붕괴는 이탈에 측정 가능한 선행 시간(턴이 아니라 일 단위 규모로 추정)을 두고 선행할 것이며, 집계된 만족도 점수로는 불가능한 조기 경보 신호로 사용 가능할 것이다.

P4. CAR은 PCS보다 리텐션과 더 강하게 상관할 것이다. 참이라면, 업계의 투자 우선순위 — 회상 충실도 — 는 공동저작 어포던스 대비 잘못 배분되어 있다.

P4가 하중을 지는 예측이다. PCS가 CAR을 압도한다면 기억 충실도 연구 프로그램은 올바르게 우선순위가 매겨진 것이고 본 논문의 논지는 틀린 것이다.

9. 안전, 의존성, 규제 제약

준사회적(parasocial) 시스템에서 지속 참여도를 개선하는 어떤 틀이든 구성상 보상 해킹 문제를 안고 있다. 2025년의 규제 전환은 이를 구체화한다. Character.AI는 2025년 11월 18세 미만 사용자의 오픈 엔디드 채팅을 종료했으며, 행동 기반 연령 추정에서 서드파티 검증, 필요 시 안면 또는 신분 확인으로 에스컬레이션하는 방식으로 이를 집행했고, 경영진은 그로 인한 이탈을 공개적으로 수용했다. 중국 규제 당국은 AI 컴패니언 서비스에 특화된 규칙을 입안했다. 미성년자가 관련된 소송은 2026년 1월 최소 한 건의 주요 사례에서 합의되었다.

따라서 우리는 목적함수를 최대화가 아니라 **제약 하 최적화**로 진술한다.

maximize $V(\delta, S)$ subject to (i) $\text{Dep}(\text{user}) \leq d$ — 의존성 지표(세션 길이 폭주, 수면 구간 침식, 고립 지표의 상승)가 임계 이하; (ii) 연령 계층 제약을 캐논 중재기의 제작자 수준 불변량으로 두어 플레이어 승격으로 무효화 불가; (iii) 단조 감사가능성 — 모든 캐논 명제가 출처를 보유하여, 임의의 하루 행동을 제작자·플레이어·모델로 역추적 가능.

NAMS에 특유한 세 가지 설계상 합의가 따른다.

- 1. δ 를 낮추는 것은 참여도 도구일 뿐 아니라 안전 도구다.** 앵커링은 시스템이 사용자 자신의 최악의 프레이밍을 세션을 가로질러 되돌려 증폭하는 기제다. 기억의 권한을 낮출 수 있는 컨트롤러는 전부-아니면-전무 기억 시스템에 없는 지렛대를 갖는다.
- 2. 모델 강등(6.4절)은 안전 기제다.** 모델이 저작한 명제가 비준 없이 캐논에 진입하는 것을 막으면, 유해한 환각적 세부가 영구적 캐릭터 진실이 되는 실패 경로가 차단된다.
- 3. CAR을 참여도와 나란히 보고해야 한다.** 참여도는 오르는데 CAR이 내려가는 플랫폼은 저작이 아니라 의존성을 생산하고 있는 것이다. 우리는 이 비율을 산업 수준 공시 후보로 제안한다.

10. 한계

근거의 질. 모든 참여도 수치는 2차 자료이며 독립 감사를 거치지 않았다. 여러 수치가 운영사의 자체 보고와 방법론이 알려지지 않은 서드파티 추정을 혼합한다. 서수적 주장(페르소나 플랫폼이 구별되는 참여도 영역을 점유한다)은 견고하지만, 개별 점추정치를 효과크기 산정에 사용해서는 안 된다.

H0는 주장이지 증명이 아니다. $V(\delta)$ 의 오목성은 기제적으로 논증되었을 뿐(포화하는 일관성에서 상승하는 예측 가능성을 뺀 형태) 측정되지 않았다. 실제로 일관성이 포화하지 않을 가능성이 있으며, 그 경우 $\delta^* = \delta_{\max}$ 이고 NAMS 계층 III은 불필요하다.

서사학적 사전지식은 문화 구속적이다. Propp 계열과 Freytag 계열 구조는 특정 전통을 부호화한다. 이들로 초기화된 스키마 탐색은 긴장 문법이 다른 연재 형식에서 성능이 떨어질 수 있다. 본 연구가 다른 세 플랫폼 중 둘이 비서구권이고, 그 콘텐츠의 상당 부분이 연재 로맨스·관계 드라마 형식이라는 점에서 이 위험은 특히 첨예하다.

모델 품질과의 교락. 기억 정책에 귀속된 개선이 실제로는 기반 모델 역량에 귀속될 수 있다. 무작위 보행 δ 절제(7.3절)가 최소한의 통제이며, 모든 실험군에 동일 기반 모델을 요구하는 것이 필수적이다.

구현의 부재. 본 논문은 설계·측정 제안이다. HOPE 자체에 공식 구현이 없고 커뮤니티 재현은 편차가 크며, ALMA의 프로덕션 규모 탐색 비용은 보고되지 않았다. NAMS는 저렴한 첫 걸음(기존 신호 위의 계층 III)을 가진 연구 프로그램으로 읽혀야 하며, 이미 구축된 시스템으로 읽혀서는 안 된다.

11. 결론

페르소나 스토리텔링 범주는 이미 참여도 논쟁에서 승리했다. 생성형 AI의 어떤 소비자 응용보다 사용자당 더 많은 주의를 점유하며, 세 개의 독립된 시장에서 수년간 그 지위를 유지해 왔다. 그러나 그 기술 문헌은 여전히 더 잘 기억함으로써 해결되는 대화 문제를 기술한다 — 더 짧은 KV 캐시, 더 긴 컨텍스트, 더 날카로운 선호 최적화.

장기 상호작용에 관한 가장 저명한 세 연구 흐름도 같은 목적함수를 물려받았다. HOPE는 기억에 원리적 주파수 구조를 부여하고, ALMA는 손으로 쓰는 대신 메모리 설계를 발견하며, SteeM만이 앵커링 병리를 명명한 뒤 사용자에게 슬라이더를 건넨다. 이들을 비교 대상이 아니라 계층으로 쌓으면 정체성·구조·제어를 모두 덮는다 — 단, 보상이 바뀔 때만 그렇다. 이야기는 최대 회상으로 봉사받지 않는다. 이야기는 자신의 기억 중 무엇이 다음 비트를 지배해야 하는지, 무엇이 흐려지도록 허용되어야 하는지, 그리고 무엇이 플레이어가 쓸 몫인지를 아는 시스템으로 봉사받는다.

NAMS는 그러한 시스템에 대한 우리의 제안이다. 정체성은 가장 느린 대역에, 내러티브 상태는 타입화되고 탐색 가능한 객체로, 기억의 권한은 업계가 이미 수집 중인 신호로 구동되는 학습된 제어 변수로,

그리고 저작은 출처를 통해 명시적으로. 이 틀은 반증 가능하다. 공동저작이 페르소나 일관성보다 리텐션을 더 잘 예측하지 못한다면(P4) 그 중심 주장은 실패한다. 우리는 이 분야가 기본값으로 회상을 최적화하기를 계속하기보다, 그 질문을 검정하기를 바란다.

참고문헌

1. Adiwardana, D., Luong, M.-T., So, D. R., Hall, J., Fiedel, N., Thoppilan, R., ... Le, Q. V. (2020). Towards a Human-like Open-Domain Chatbot. arXiv:2001.09977.
2. Behrouz, A., Zhong, P., & Mirrokni, V. (2025). Titans: Learning to Memorize at Test Time. arXiv:2501.00663.
3. Behrouz, A., et al. (2025). Nested Learning: The Illusion of Deep Learning Architectures. NeurIPS 2025. (관련: Google Research Blog, "Introducing Nested Learning: A new ML paradigm for continual learning", 2025년 11월.)
4. Freytag, G. (1863). Die Technik des Dramas.
5. Hu, S., Lu, C., & Clune, J. (2024). Automated Design of Agentic Systems. arXiv:2408.08435.
6. Laban, P., et al. (2025). LLMs Get Lost in Multi-Turn Conversation. arXiv:2505.06120.
7. Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2023). Lost in the Middle: How Language Models Use Long Contexts. arXiv:2307.03172.
8. MiniMax (2025a). MiniMax-01: Scaling Foundation Models with Lightning Attention. arXiv:2501.08313.
9. MiniMax (2025b). MiniMax-M1: Scaling Test-Time Compute Efficiently with Lightning Attention. arXiv:2506.13585.
10. Packer, C., Fang, V., Patil, S. G., Lin, K., Wooders, S., & Gonzalez, J. E. (2023). MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560.
11. Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. UIST 2023.
12. Propp, V. (1928). Morphology of the Folktale.
13. Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS 2023.
14. Riedl, M. O., & Bulitko, V. (2013). Interactive Narrative: An Intelligent Systems Approach. AI Magazine, 34(1).

15. 스캐터랩 기술 블로그 (2025-2026). 「유저와 함께 만드는 LLM — 제타에 Preference Optimization 도입하기」 ; 「유저와 함께 만드는 LLM 2편 — 제타에 Online Learning 도입하기」 . blog.scatterlab.co.kr
16. Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Zhang, M., ... Guo, D. (2024). DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO). arXiv: 2402.03300.
17. Shazeer, N. (2019). Fast Transformer Decoding: One Write-Head is All You Need. arXiv: 1911.02150.
18. Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., & Dean, J. (2017). Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. ICLR 2017.
19. Thoppilan, R., et al. (2022). LaMDA: Language Models for Dialog Applications. arXiv: 2201.08239.
20. Tian, M., et al. (2026). Controllable Memory Usage: Balancing Anchoring and Innovation in Long-Term Human-Agent Interaction. arXiv:2601.05107.
21. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. NeurIPS 2017.
22. Xiong, Y., Hu, S., & Clune, J. (2026). Learning to Continually Learn via Meta-learning Agentic Memory Designs (ALMA). arXiv:2602.07755.
23. Character.AI Research (2024). Optimizing AI Inference at Character.AI; Prompt Poet (오픈소스 공개).

Abstract (English)

Persona large language model (LLM) platforms have quietly become the highest-dwell-time consumer application category of the generative AI era. Field data from the three most durable deployments — zeta (Scatter Lab), Character.AI, and Talkie/Xingye (MiniMax) — show per-user daily engagement of 70 to 150 minutes sustained over multiple years. Yet the research literature these systems draw on frames their central difficulty as a **memory** problem: how faithfully a system can recall and re-inject the past. We argue this framing is category-incorrect. Comparing three currently prominent research lines — Nested Learning/HOPE (parametric multi-timescale memory), ALMA (meta-learned agentic memory design), and SteeM (user-controllable memory dependence) — we show that all three optimize **fidelity of recall**, whereas the empirical failure mode of long-horizon

persona storytelling is **anchoring**: high-fidelity recall drives narrative predictability, and predictability drives disengagement. We formalize this as the **Narrative Vitality Frontier**, a concave relationship between memory dependence δ and sustained engagement admitting an optimum $\delta^*(\tau)$ that drifts with relationship age τ . We propose **NAMS (Narrative-Adaptive Memory Stack)**, a three-layer architecture separating (I) a slow-updating Persona Core enforcing identity invariants, (II) a meta-learned Narrative State schema carrying narratological rather than factual variables, and (III) a learned Steering Controller that sets δ from interaction signals platforms already collect. We contribute a metric suite (PCS, NNI, TAR, CAR), a longitudinal benchmark design (PERSONA-ARC), four falsifiable predictions, and a constrained objective subordinating engagement maximization to dependency and minor-safety constraints. The central claim: the field's next advance will come not from remembering more, but from deciding what a story should do with what it remembers.

Keywords: persona LLM, interactive narrative, long-term memory, continual learning, memory anchoring, human-agent interaction, preference optimization, AI safety